

Unyi Péter Álmos

Nagy házifeladat – Huffman-kódolás program dokumentációja

Rövid leírás:

A nagy házifeladatomban egy parancssorból futtatható, szövegeket veszteségmentesen tömörítő program, amely a Huffman-algoritmust használja fel a tömörítésre.

Felhasznált könyvtárak és függőségek:

- `stdio.h`;
- `stdlib.h`;
- `stdbool.h`;
- `string.h`;
- `ctype.h`;
- `debugmalloc.h`;

Típusok:

- Gyakoriság: struct a szövegben található karakterek gyakoriságának a tárolására.
 - a. `char betu`: a karakter, aminek a gyakoriságát tárolja a `.gyakorisag` paraméter;
 - b. `int gyakorisag`: a karakter előfordulásának a száma az adott szövegben.
- Binfa: bináris fa tárolására;
 - a. `int szam`: a bináris fában található levél esetén a levél által tárolt karakter előfordulásának a száma, belső adatpont esetén pedig a két alatta lévő gyerek `.szam` paramétereinek az összege;
 - b. `char betu`: a bináris fában található levél esetén a kódolt karakter, belső adatpont esetén pedig null;
 - c. `char *ut`: a Huffman-kódolt fában az adatpontok elérési útvonala bináris kódban kifejezve, ami alapján el lehet jutni a kódolt ponthoz a gyökértől kezdve;
 - d. `struct Binfa *bal, *jobb`: a bináris fa egy gyökerének a két levelére mutató pointer, melyeknek típusa szintén `Binfa`.
- Kod: a kitömörítéshez használt struct, amiben a kódolt karakterek bináris kódjait („elérési útvonalait”) lehet tárolni;
 - a. `char betu`: a kódolt karakter;
 - b. `int meret`: a kódolt bitsorozat mérete;
 - c. `char *kod`: a bináris kód, ami a karakterhez tartozik és ami alapján megkereshető a fában, mindig byte méretű.

Fájlok és funkciók:

`huffman.c`

- Főprogram, kommunikáció a felhasználóval, ez választja szét a betömörítés és a kitömörítéshez szükséges programokat, illetve kezeli az esetleges felmerülhető problémákat a programhoz beírt utasítások kapcsán.
- Argumentumok: bemeneti opciók, `char *argv[]` array-ben tárolva;

- Visszatérési érték: 0, a felmerülő problémákat kiírja a képernyőre.

betomorites.c**1. FILE *fajl_letrehoz(char *fajlnev)**

- Függvény fájl létrehozására. Létrehoz egy fájl, aminek az elérési útvonalát argumentumként kapta meg, majd visszatér a létrehozott filepointerrel.
- Argumentumok:
 - char *fajlnev: a fájl elérési útvonala.
- Visszatérési érték:
 - sikertelen létrehozáskor: NULL;
 - sikeres létrehozáskor: FILE *fajl: a fájlt tartalmazó pointer.

2. int fajlmeret(FILE *fajlp)

- Függvény egy fájl méretének a meghatározására. Eltárolja és visszatér az argumentumként kapott filepointer byteokban számolt méretével.
- Argumentumok:
 - FILE *fajlp: a fájlt tartalmazó pointer.
- Visszatérési érték:
 - int fajlmeret: a fájl mérete byteokban.

3. char *fajl_olvas(char *fajlnev)

- Függvény egy file tartalmának az olvasására. Megnyitja az argumentumként kapott elérési útvonalon lévő file-t és karakterenként kiolvassa belőle a tartalmát, ezt eltárolja egy char pointerben, majd ezzel tér vissza.
- Argumentumok:
 - char *fajlnev: a file elérési útvonala.
- Visszatérési érték:
 - sikertelen file megnyitáskor: NULL;
 - sikeres olvasáskor: char *string: a szöveget tartalmazó char pointer.

4. int fajl_ir(char *fajlnev, char *tartalom)

- Függvény egy tartalom file-ba írására. Megnyitja az argumentumként kapott elérési útvonalon található file-t és beleírja az argumentumként kapott tartalmat, majd visszatér a file-ba írt karakterek számával.
- Argumentumok:
 - char *fajlnev: a file elérési útvonala
 - char *tartalom: a file-ba írandó szöveges tartalom char pointere
- Visszatérési érték:
 - sikertelen file megnyitáskor: NULL;
 - sikeres file-ba íráskor: int kar_count: a file-ba írt karakterek száma

5. void bemenet_eldont(char opcio, char *arg1, char *arg2, char *arg3)

- A betomorites.c file vezérlő függvénye, ez vezérli a betömörítés folyamatát. Az opcio argumentumból megkapja a betömörítés típusát, ami f (fileből olvas be) és s (begépelt szövegből olvas be) típus lehet, ez alapján eldönti, honnan kell beolvasni a tömörítendő szöveget. Megszámolja a karakterek gyakoriságát a beolvasott sztringben, létrehoz egy bináris fát, és megállapítja a karakterek tömörített kódjait, majd a kódolt szöveget is létrehozza, ezen utóbbiakat a binaris_fa.c file-ból vett függvények segítségével.
- Argumentumok:

- char opcio: a beolvasás típusa, értékei: f (fileből olvas be), s (begépelt szövegből olvas be);
- char *arg1: opcio = f esetén: a beolvasandó file elérési útvonala, opcio = s esetén a begépelt szöveg;
- char *arg2: az egyedi kimeneti file választó opciója, ha NULL, nem kell létrehozni egyedi file-t;
- char *arg3: ha szükséges létrehozni egyedi kimeneti file-t, akkor a program az arg3 paraméterként kapott elérési útvonalon található file-ba tömörít, alapértelmezése: tomoritett.hcf.

binaris_fa.c

1. **Gyakorisag *rendezes_struct(Gyakorisag *t, int meret)**
 - Függvény, ami egy Gyakorisag típusú tömböt tud rendezni, az előfordulások száma alapján növekvő sorrendben;
 - Argumentumok:
 - Gyakorisag *t: az előfordulásokat tartalmazó Gyakorisag típusú tömb;
 - int meret: a tömb mérete.
 - Visszatérési érték:
 - Gyakorisag *t: a rendezett tömb.
2. **Gyakorisag tombelem_torol_struct(Gyakorisag *t, int p, int meret)**
 - Funkció egy tömbelem törlésére egy Gyakorisag típusú listából, a p-edik pozícióról.
 - Argumentumok:
 - Gyakorisag *t: maga a tömb, ahonnan törlésre kerül egy elem;
 - int p: a törlendő elem pozíciója;
 - int meret: a tömb mérete.
 - Visszatérési érték:
 - Gyakorisag *t: a tömb, a törölt elem nélkül.
3. **void sorban_kiir(Binfa *gyoker)**
 - Rekurzívan végigmegy a bináris fán, és kiírja az elemeit preorder algoritmussal. Debug függvény.
 - Argumentumok:
 - Binfa *gyoker: a bináris fa első elemét tartalmazó pointer.
 - Visszatérési érték: -
4. **Binfa *lefoglal(int szam)**
 - Lefoglal egy új elemet a bináris fában, a következő adatokkal:
 - int .szam = szam (a függvény paramétere);
 - char .betu = NULL;
 - char .ut = NULL;
 - Binfa *bal, *jobb = NULL;
 - Argumentumok:
 - int szam: a bináris fa adatpontjához tartozó gyakorisági szám.
 - Visszatérési érték:
 - Binfa *uj: a létrehozott és memóriában lefoglalt memóracím.
5. **bool level(Binfa *gyoker)**

- Megvizsgálja, hogy levél-e az adott adatpont a bináris fában és bool értékkel tér vissza.
 - Argumentumok:
 - Binfa *gyoker: a bináris fa egy adatpontja;
 - Visszatérési érték:
 - bool level: igaz, vagy hamis, hogy az adatpont levél-e.
6. **char *tomb_megnovel(char *t)**
- Funkció, ami megnöveli char tömb méretét, úgy hogy újabb elemeket lehessen beszúrni.
 - Argumentumok:
 - char *t: a megnövelendő tömb.
 - Visszatérési érték:
 - char *uj: az lefoglalt memória, amibe további elemeket tudunk beszúrni.
7. **Binfa *beszur(Binfa *gyoker, int osszeg, int a, int b, char ca, char cb)**
- Függvény az összegfa felépítésére. Megkeres két gyakoriság számának az összegét a fában és ha létezik, továbbá az adott adatpont levele a fának, beszúrja a két adatot, a gyakoriságokhoz tartozó karakterekkel együtt.
 - Argumentumok:
 - Binfa *gyoker: a bináris fa első elemét tartalmazó pointer;
 - int a, int b: a két gyakorisági szám;
 - char ca, char cb: a két gyakorisághoz tartozó karakterek.
 - Visszatérési érték:
 - Binfa *gyoker: a bináris fa első elemét tartalmazó pointer.
8. **Binfa *rekurziv_tomb(Gyakorisag *n, int meret)**
- Rekurzívan végigmegy egy tömbön, és minden rekurzióban rendez a tömböt, összedja az első két elem értékét, beszúrja a tömbbe és amikor elfogynak az elemek, vagy egy elem marad, létrehoz egy bináris fát és meghívva a beszur függvényt, beszúrja a bináris fába a tömb első két elemét, visszatér a létrehozott és adatokkal feltöltött bináris fával.
 - Argumentumok:
 - Gyakorisag *n: a karaktereket és gyakoriságukat tartalmazó tömb;
 - int meret: az előző tömb mérete.
 - Visszatérési érték:
 - Binfa *r: a létrehozott és adatokkal feltöltött fa.
9. **void binaris_fajl_ir(char *t, FILE *f)**
- Egy tetszőleges méretű, 1-es és 0-s elemű tömböt ír fájlba, az eredeti tömböt byte méretű rész-sztringekre felosztva és a benne található 1-es, 0-s elemek szerint. Ha a rész-sztring kisebb méretű mint 8, feltölti 0-s karakterekkel.
 - Argumentumok:
 - char *t: a bináris kódot tartalmazó tömb;
 - FILE *f: a fájlra mutató pointer.
 - Visszatérési érték: -
10. **void kodok_fileba(Binfa *gyoker, FILE *f)**
- Fájlba írja a Huffman-kódolt betűk bináris reprezentációját. Rekurzívan, preorder sorrendben megy végig a fán, ha az adott pont levél a fában, fájlba írja a karaktert és a hozzá tartozó „elérési útvonalat” a fában.
 - Argumentumok:

- Binfa **gyoker*: a bináris fa első elemét tartalmazó pointer;
 - FILE **f*: a fájlra mutató pointer.
 - Visszatérési érték: -
11. ***char *faban_keres(Binfa *gyoker, char c, char *t, FILE *f)***
- Végigmegy rekurzívan a bináris fán és megkeres benne egy karaktert, ha megtalálta, a paraméterként átadott **t* tömbbe másolja az „elérési utat” és visszatér ugyanezzel a tömbbel.
 - Argumentumok:
 - Binfa **gyoker*: a bináris fa első elemét tartalmazó pointer;
 - char *c*: a fában keresett karakter;
 - char **t*: a tömb, amit címként vesz át a függvény, hozzáfűzi a karakter „elérési útvonalát”;
 - FILE **f*: a fájlra mutató pointer.
 - Visszatérési érték:
 - char **t*: a karaktertömb, belemásolva a keresett karakter „elérési útvonala”.
12. ***Gyakorisag *gyak_szamol(char *szoveg, int *cel_meret)***
- Függvény, ami megszámolja egy szövegben található karakterek gyakoriságát, majd ezeket eltárolja egy Gyakorisag típusú tömbben és visszatér ezzel.
 - Argumentumok:
 - char **szoveg*: a szövegtömb, ahol meg kell számolni a karaktereket;
 - int **cel_meret*: a kimeneti tömb mérete, amit a függvény címként kap meg és ezt később a program felhasználja.
 - Visszatérési érték:
 - char **cel*: a céltömb, ahová bemásolásra kerültek a betűk és gyakoriságaik.

kitomorites.c

1. ***int kod_tabla_meret(char *t)***
 - Függvény, ami megmondja, hogy a tömörített fájlban hány karakter van kódolva, visszatérési értéke ez a szám.
 - Argumentumok:
 - char **t*: a fájlból beolvasott szöveg.
 - Visszatérési érték:
 - int *j*: a kódolt karakterek száma.
2. ***Kod kodok_beolvas(char *s)***
 - Függvény, ami beolvassa a kódolt karakterek táblázatát, ami a következő mezőket tartalmazza: betű | fontos bitek | a betű Huffman-kódja. Ezeket egy Kod típusú tömbbe másolja be és ezt adja vissza.
 - Argumentumok:
 - char **s*: a fájlból beolvasott szöveg, ami tartalmazza a kódolt betűk listáját.
 - Visszatérési érték:
 - Kod kodok: a kódolt betűk, eltárolva egy Kod típusú tömbben.
3. ***char *tomoritett_szoveg_beolvas(char *s, int meret)***
 - Függvény, ami beolvassa egy karakter típusú tömbbe a tömörített szöveget a fájlból és ezzel tér vissza.

- Argumentumok:
 - char *s: a fájlból beolvasott szöveg;
 - int meret: a szöveg mérete.
 - Visszatérési érték:
 - char *t: a beolvasott tömörített szöveg.
4. **void dekodol(Kod *kod_tabla, int k_meret, char *s, int s_meret)**
- Függvény a tömörített szöveg visszaállítására karakterenként. Még nem teljes, nincs visszatérési értéke, továbbá esetenént rossz karaktereket ír ki.
 - Argumentumok:
 - Kod *kod_tabla: a kódolt betűket tartalmazó Kod típusú tömb;
 - int k_meret: a kódolt betűk darabszáma;
 - char *s: a fájlból beolvasott szöveg;
 - int s_meret: a fájlból beolvasott szöveg mérete.
 - Visszatérési érték: -
5. **void kitomoritt(char opcio, char *tomoritett_fajl, char *visszaallitott_fajl)**
- A kitormorites.c fájl vezérlő függvénye, amit a huffman.c hív meg. Ez végzi a kitömörítést végző függvények hívását és eldönti, hogy a visszaállított fájlt a standard kimenetre, vagy fájlba írja ki.
 - Argumentumok:
 - char opcio: kapcsoló, eldönti, hogy fájlba vagy a standard kimenetre írja ki a visszaállított fájl tartalmát;
 - char *tomoritett_fajl: a tömörített .hcf fájl, amiből történik a beolvasás;
 - char *visszaallitott_fajl: a kimeneti fájl elérési útvonala, ha NULL, a standard kimenetre írja ki a szöveget.
 - Visszatérési érték: -